論文要約

LLM関連

Automated Evaluation of Retrieval-Augmented Language Models with Task-Specific Exam Generation タスク特化型試験生成による検索強化型言語モデルの自動評価

概要: RAGの評価方法の提案

タスクに関連する文書コーパスに基づく多肢選択式問題から自動生成された合成試験にRAGをスコアリングすることで実施。試験の品質とタスク特化型精度に関する情報量を推定するために項目反応理論 (IRT) を活用することで試験を段階的に改善します

技術や手法

本研究で説明されている技術や手法は次の通りです:

1. **試験生成**:
    - LLMを用いて、文書コーパスに基づく多肢選択式試験問題を自動生成。
    - 各質問には1つの正解と複数の選択肢が含まれます。
    - 各文書から質問候補を生成し、NLPベースのフィルターを適用して低品質な質問を除外。
    - 試験生成プロンプト例

```markdown
Human: Here is some documentation from {task_domain}: {documentation}. From this, generate
a difficult multi-form question for an exam. It should have 4 candidates, 1 correct answer
and explanations.

Syntax should be:
Question: {question}
A) {candidate A}
B) {candidate B}
```

Concise Thoughts: Impact of Output Length on LLM Reasoning and Cost 簡潔な考え：LLMの推論とコストにおける出力長の影響

概要：LLMでCoTを使用すると説明能力を向上させる半面、出力が長くなり応答に時間がかかるため、出力長を制御するプロンプトエンジニアリング制約付き CoT（CCoT）を紹介。出力の長さを制約するプロンプトを与え、出力の簡潔さと応答時間の予測可能性を向上させます。

つくり方は、Let's think a bit step by step の後に limit the answer length to 45 words. のような制限の指定をするだけ

技術や手法

1. **新しい評価指標の提案 **

   - **硬直な簡潔精度（ Hard-k Concise Accuracy: HCA）**: 指定された長さ k以下の正確な出力の割合を測定します。

   - **柔軟な簡潔精度（ Soft-k Concise Accuracy: SCA）**: 長さkを超える正確な出力に対して減衰因子 αを用いてペナルティを課します。

   - **一貫した簡潔精度（ Consistent Concise Accuracy: CCA）**: 出力長のばらつき σに基づいて SCAをさらに調整します。

2. **制約付き CoT（CCoT）の導入 **

   - **CCoTプロンプト **: LLMに対して出力の長さを制約するプロンプトを与え、出力の簡潔さと応答時間の予測可能性を向上させます。

Retrieval Augmented Generation or Long-Context LLMs? A Comprehensive Study and Hybrid Approach 検索拡張生成か長文コンテキスト LLMか？包括的研究とハイブリッドアプローチ

概要: RAGと長文コンテキスト（ LC）の比較を行いました。結果として、リソースが十分にあれば LCが平均的な性能で RAGを上回ること、RAGは大幅に低コストであるという利点があること、この結果を基にモデルの自己反省に基づいてクエリを RAGまたはLCにルーティングする SELF-ROUTEという方法を提案。

計算コストを大幅に削減しながら、 LCと同等の性能を維持できます。

技術や手法

以下の3つの手法の比較を行っています

1. **RAG (Retrieval Augmented Generation)**:
    - クエリに基づいて関連情報を検索し、 LLMがその情報を使用して応答を生成する。
    - クエリに関連する情報を取得し、 LLMの注意を必要なセグメントに集中させることで、無関係な情報による注意の分散を防ぐ。
    - 計算コストが低い。
2. **長文コンテキスト（ LC）LLMs**:
    - 大規模な事前学習により、長文コンテキストを直接理解する能力を持つ。
    - 例: Gemini-1.5（最大1百万トークンを処理可能）、 GPT-4（128kトークンを処理可能）。
3. **SELF-ROUTE**:
    - クエリを RAGまたはLCにルーティングする方法。
    - モデルの自己反省に基づいてクエリが回答可能かどうかを予測し、回答可能な場合は RAGを使用し、そうでない場合は LCを使用する。

Tulip Agent – Enabling LLM-Based Agents to Solve Tasks Using Large Tool Libraries チューリップエージェント – 大規模ツールライブラリを使用してタスクを解決する LLMベースエージェントの実現

概要: LLMのエージェント tulip agentを紹介

ツールの説明をシステムプロンプトにエンコードせず、また全体のプロンプトを埋め込むことなく、再帰的にツールライブラリから適切なツールを検索することで実現します

技術や手法の詳細説明

タスク分解

概要:

ユーザーからの自然言語クエリを受け取り、 LLM（大規模言語モデル）が高レベルのタスクを理解し、細分化されたサブタスクに分解します。これにより、具体的かつ実行可能な単位でタスクを処理できます。

詳細:

1. **ユーザークエリの受信 **:
    - エージェントはユーザーからの自然言語による質問や要求を受け取ります。
    - 例: "What is 45342 multiplied by 23487 plus 32478?"
2. **タスク分解モデル (Mtd)**:
    - このモデルは、受信したクエリを解析し、それをサブタスクに分解します。

Tree-of-Traversals: A Zero-Shot Reasoning Algorithm for Augmenting Black-box Language Models with Knowledge Graphs トラバースツリー：ブラックボックス言語モデルをナレッジグラフで拡張するゼロショット推論アルゴリズム

概要：LLMを1つまたは複数の KGで拡張できるファインチューニングなしでゼロショットな　Tree-of-Traversalsを紹介 KGを利用して可能な思考とアクションをツリー検索で行うことにより、高信頼の推論経路を見つけます

1. Tree-of-Traversals アルゴリズム

Tree-of-Traversalsは、ブラックボックス LLMを複数のナレッジグラフ（ KG）で拡張するゼロショット推論アルゴリズムです。このアルゴリズムは、　KGとインターフェースをとるアクションを　LLMに装備し、ツリー検索を行うことで高信頼の推論経路を見つけ出します。

1.1 知識グラフインターフェース　(Knowledge Graph Interface)

Knowledge Graph Interfaceは、LLMがKGと相互作用するためのメソッドを提供します。

- `initialize(q) → E0`: クエリqを入力として受け取り、 qからエンティティを抽出し、 KGに存在するリンクされたエンティティ　E0を返します。

- `get_relations(Eselected) → Roptions`: 選択されたエンティティの集合　Eselectedを受け取り、KG内の利用可能なリレーションタイプ　Roptionsを返します。

- `get_edges(Eselected, r) → Tadded, Eadded`: 選択されたエンティティの集合と選択されたリレーションタイプ　rを受け取り、そのリレーションタイプを持つエッジを返します。また、新たに追加されたエンティティ　Eaddedも返します。

1.2 アクションステートマシン　(Action State Machine)

ThinkRepair: Self-Directed Automated Program Repair ThinkRepair: 自律型自動プログラム修復

概要: 自動プログラム修復(APR)アプローチとして LLMを使用する ThinkRepairを提案。2フェーズで構成され収集フェーズでは CoTプロンプトを使い事前に固定された知識を自動収集、修正フェーズでは、few-shotのための例を提示しテスト情報のフィードバックを追加することでバグ修正を行います

ThinkRepairアルゴリズムと手法

収集フェーズ

このフェーズは、様々な考え方のチェーン(Chain-of-Thought, CoT)を収集し、知識プールを構築することを目的としています。

1. **プロンプトの準備 **

- **英語**: The prompt used in ThinkRepair involves four important components:

1. Role Designation: ThinkRepair starts a role for LLM with an instruction like “You are an Automated Program Repair tool”.

2. Task Description: LLM is provided with the description constructed as “// Provide a fix for the buggy function”. Since we illustrate an example in Java, we use the Java comment format of “//” as a prefix.

3. Buggy Function: ThinkRepair provides the buggy function to LLM in our single-function fixing scenario. We also prefix the buggy function with “// Buggy Function” to directly indicate LLM about the context of the function.

4. Chain-of-Thought Indicator: LLM is instructed to think step-by-step when fixing a bug. In this paper, we follow the best practice in previous work and adopt the same prompt named “Let’s think step by step”.

- **日本語**: ThinkRepairで使用されるプロンプトには、次の四つの重要なコンポーネントが含まれます。

1. 役割の指定: ThinkRepairは「あなたは自動プログラム修復ツールです」という指示で、LLMに役割を与えます

TestART: Improving LLM-based Unit Test via Co-evolution of Automated Generation and Repair Iteration TestART: 自動生成と修復反復の共進化による LLMベースの単体テストの改善

概要: 単体テストを LLMを使用して生成する TestARTを提案。テンプレートベースの事前に定義された修復パターンを使用してコードのバグを自動的に修正。修正されたコードや追加の指示をプロンプトインジェクションとして LLMに与え、次の自動生成ステップを誘導します。テストケースからカバレッジ情報を抽出し、テストフィードバックとして使用します。

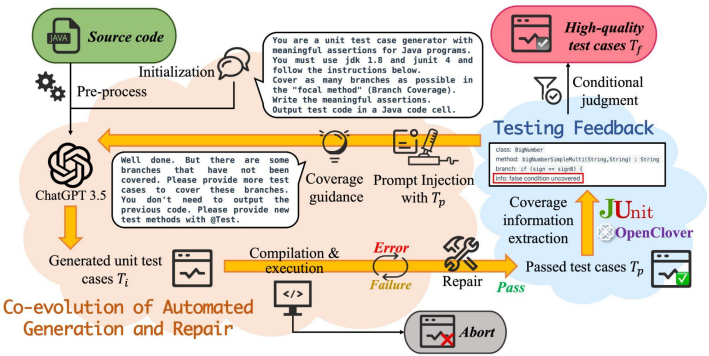

1. 前処理

目的: ソースコードを LLMが処理しやすい形にする。

- **コメント削除 **: コード内のコメントや余分な空白行を削除します。これは、コードの冗長性を減らし、 LLMが必要な情報に集中できるようにするためです。

- **コード圧縮 **: メソッド署名のみを残し、焦点となるメソッドの完全なメソッドボディを保持します。これにより、 LLMが扱うテキストの長さを適切に保ち、無関係な情報の干渉を減らします。

2. 生成と修復の共進化

Automated Defects Detection and Fix in Logging Statement ログステートメントにおける欠陥の自動検出と修正

概要: ログステートメントは、ソフトウェアの動作を記録しますが、誤解を招くログが保守を複雑にするため　　LogFixerでは、合成された欠陥ログを使い、類似性に基づく　4分類器を作成。この分類器は、ログステートメントを評価し、修正が必要かどうかを判断します。次に、過去のログ修正履歴を使い、　　LLMを使用して修正の提案を行います。

技術や手法の詳細説明

LogFixerの手法については以下になります。

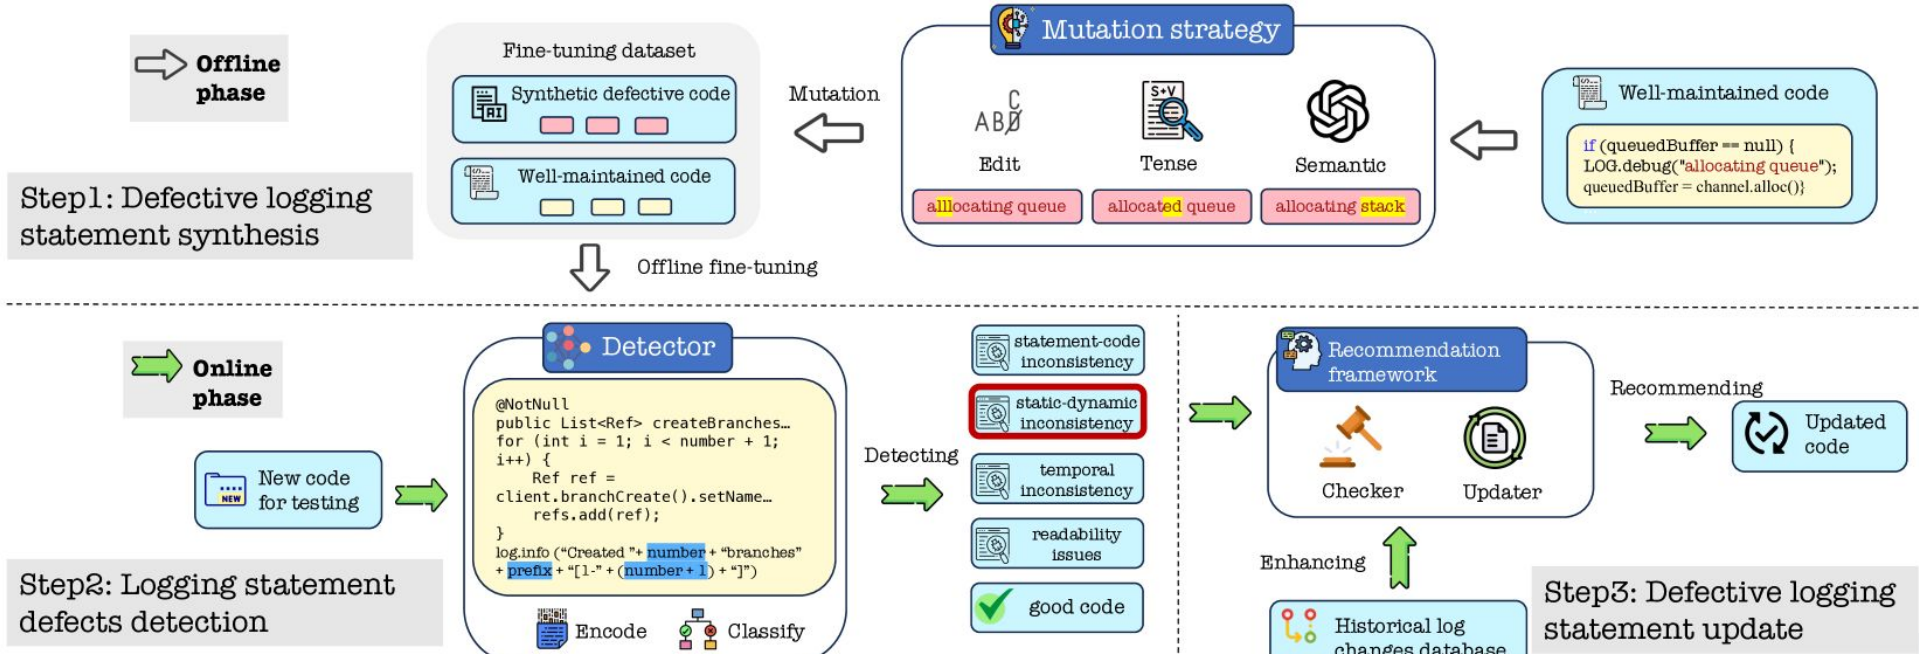

SpecRover: Code Intent Extraction via LLMs SpecRover: LLMを用いたコード意図抽出

概要: LLMを使用した自動プログラム改善手法　SpecRoverはプロジェクトの構造と動作から意図を抽出、仕様を推論、その仕様を基にパッチを生成し、そのパッチの信頼性を確認するためにレビューエージェントを使い、パッチの品質を高めるために、反復的な仕様推論とレビューを行います。

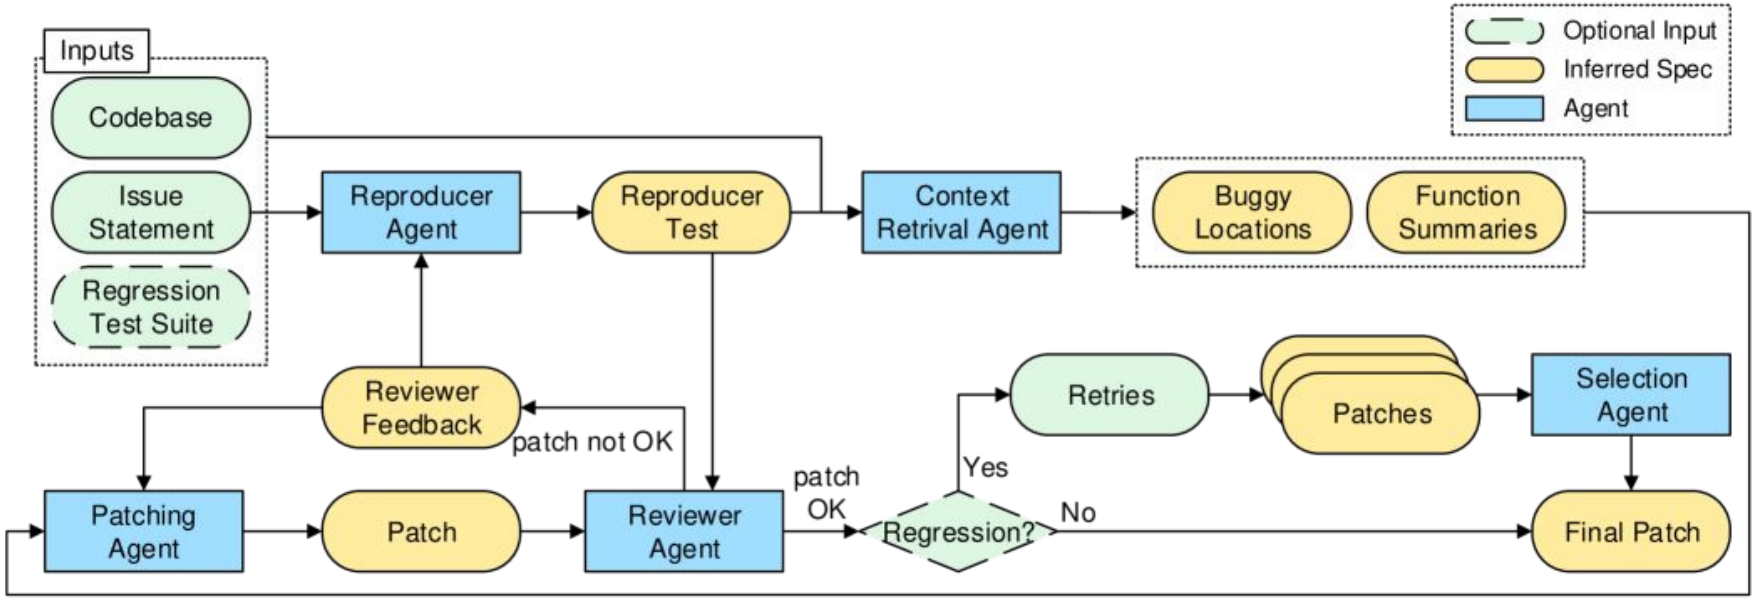

技術や手法 :

SpecRoverのフローは以下になっています

1. 問題設定と概要

Conversational Prompt Engineering 対話型プロンプトエンジニアリング

概要: LLMと対話しながらユーザーの出力の好み追加してタスクに応じたプロンプトを作成する　Conversational Prompt Engineering (CPE)を提案。ユーザーが提供するラベルなしデータを基に質問を生成して、初期の指示を作り、その後、ユーザーのフィードバックを基にさらにプロンプトを洗練させます。

Conversational Prompt Engineering (CPE)の手法

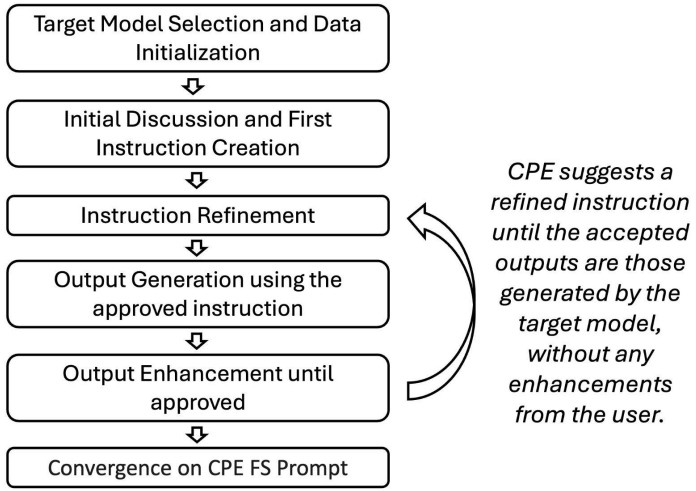

1. プロンプト生成のプロセス

1.1 ユーザーからのデータ提供

CPEのプロセスは、ユーザーがラベルなしのデータを提供するところから始まります。このデータは、後続のプロンプト生成に利用される重要な材料です。例えば、ユーザーが映画のレビューを要約したい場合、3つの映画レビューのサンプルを　CPEにアップロードします。

1.2 データ分析

提供されたラベルなしデータは、 CPEによって分析されます。 CPEはこのデータを用いて、ユーザーのタスクに関連する要素を特定します。例えば、映画レビューの場合、レビューの中でプロット（物語の概要）やレビュアーの意見など、要約に重要な情報が含まれているかを分析します。

1.3 データ駆動型の質問の生成

RAGEval: Scenario Specific RAG Evaluation Dataset Generation Framework RAGEval: シナリオ特化型の RAG評価データセット生成フレームワーク

概要: RAGEvalは、シナリオ特化型の評価データセットを生成するフレームワークで、スキーマを使い、縦割りドメインごとにドキュメントを生成、これを基に質問応答ペアを作成し、 Completeness、Hallucination、Irrelevanceという指標を使用し応答を評価します

技術と手法

1. スキーマ要約 (Schema Summary)

概要: ドメイン固有のシナリオでは、テキストは通常、共通の知識フレームワークに従います。このフレームワークをスキーマと呼び、ドメイン固有の知識を体系的にまとめたものです。 RAGEvalでは、少数の種ドキュメントを分析して、このスキーマを抽出します。

手順:

- **ドキュメントの選定 **: ドメイン固有のいくつかのドキュメントを種として選びます。

- **LLMを使用した帰納推論 **: 選定した種ドキュメントを用いて、 LLMを使用し、ドメインに特有の情報（例えば、組織名、イベント、日時、場所など）を要約します。

- **スキーマの確立 **: 上記の帰納推論の結果をまとめ、ドキュメントの基本構造を定義するスキーマを作成します。このスキーマは、そのドメインに特有の重要な情報を網羅することを目指します。

2. ドキュメント生成 (Document Generation)

From LLMs to LLM-based Agents for Software Engineering: A Survey of Current, Challenges and Future LLMからソフトウェアエンジニアリング向け　LLMベースエージェントへ：現状、課題、将来に関する調査

概要：LLMとLLMベースエージェントの能力を明確に区別し、　SEにおける要件工学、コード生成、自律的意思決定、設計、テスト生成、保守という　6つの主要トピックについてどのように使用されているかを調査

それぞれのトピックにおいて、 LLMは主に自動化と効率化を支援し、 LLMベースエージェントはその能力をさらに拡張し、より複雑で自律的なタスクを処理する役割を果たしていました

1. 要件工学

LLMの適用

LLM（大規模言語モデル）は要件工学において、要件の抽出、分類、生成、曖昧性の検出、および品質評価に利用されています。

- **要件抽出と分類 **: LLMは自然言語で記述された要件文書から、機能要件と非機能要件を自動的に抽出し、分類することができます。これにより、開発者は要件の整理と分析を効率的に行うことができます。

- **要件生成 **: LLMを使用して、ソフトウェア要件仕様書（ SRS）を自動生成することができます。例えば、ユーザーの要求やシステムの目的を自然言語で入力することで、　LLMがそれを解析し、詳細な要件文書を生成します。

- **曖昧性の検出 **: LLMは、要件文書内の曖昧な表現を検出し、明確化のための提案を行います。これにより、誤解を防ぎ、要件の品質を向上させることができます。

- **品質評価 **: LLMは、要件文書の品質を評価し、不足や矛盾点を指摘することができます。これにより、要件の信頼性を向上させることが可能です。

LLMベースエージェントの適用

Evaluating RAG-Fusion with RAGElo: an Automated Elo-based Framework RAG-Fusionの評価：RAGEloを用いた自動 Eloベースフレームワ

概要: RAGによるQAの自動評価で企業内タスクに対するベンチマークの不足に対応するために　LLMを活用してユーザーの実際のクエリとドメイン内の文書に基づく合成クエリの大規模データセットを生成し、自動EloベースのRAGエージェントの異なるバリエーションをランク付けする包括的な　RAGElo評価フレームワークを提案。

製品QAタスクにおいて RAGとRAGFを評価し、RAGEloの評価基準によると RAGFの方が優れた回答をすることがわかりました

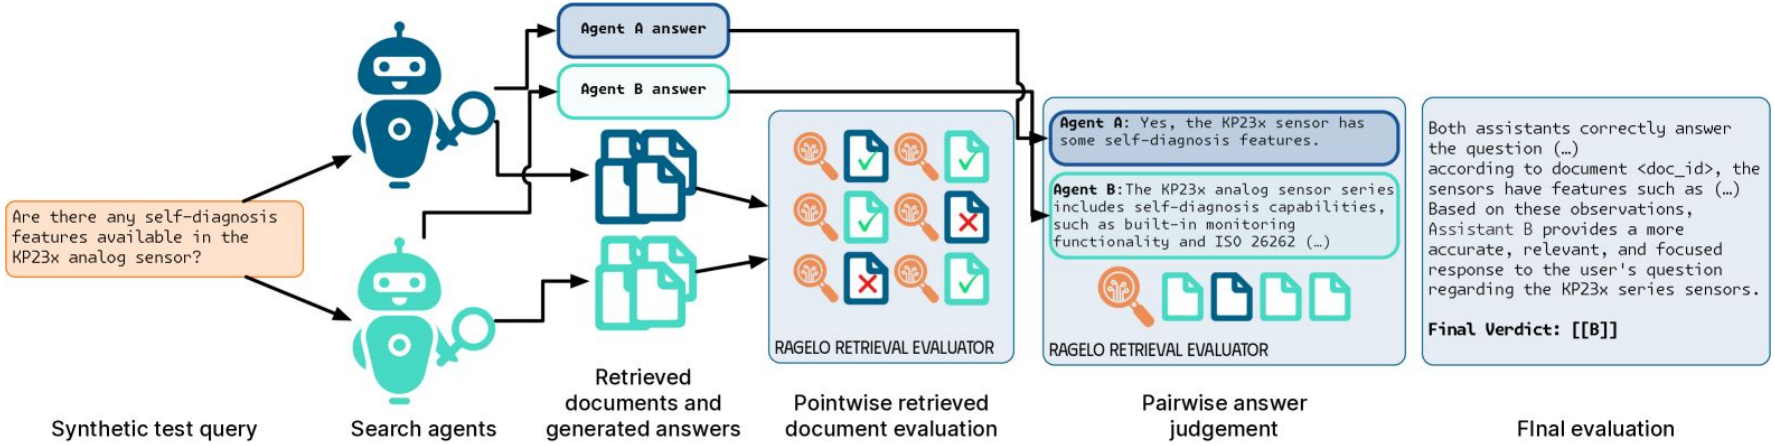

RAGElo evaluation pipeline

技術と手法について

**RAGEloフレームワーク **:

RAGEloは、Eloランキングシステムに基づいた評価ツールキットで、　RAGシステムによって生成されたドキュメントや回答を評価するために、　LLMをジャッジとして使用します。

Large Language Models for Secure Code Assessment: A Multi-Language Empirical Study 安全なコード評価のための大規模言語モデル　: 多言語での実証的研究

概要: Python, C, C++, Java, JavaScriptを対象にリアルタイム脆弱性分析を行う　CODEGUARDIANを開発、GPT-4 TurboとGPT-4oは、他の LLMと比較して特に脆弱性検出と　CWE分類のタスクで他の　LLMよりも優れており、few-shotプロンプトがさらに効果をあげることがわかりました

- **LLMの評価 **: 複数のプログラミング言語に対して、　GPT-3.5-Turbo, GPT-4 Turbo, GPT-4o, CodeLlama-7B, CodeLlama-13B, Gemini 1.5 Proの6つのLLMを使用して、脆弱性検出および　CWE分類の能力を評価。

- **データセットの構築 **: 5つのプログラミング言語で　370以上の手動で検証された脆弱性を含むデータセットを構築し、脆弱性検出と分類の評価に使用。

- **プロンプト戦略 **: 脆弱性検出と CWE分類のために、複数のシステムプロンプトおよびユーザープロンプトを設計し、　LLMの性能を最適化。

- **CODEGUARDIANの開発 **: VSCodeの拡張機能として、LLMを活用してリアルタイムでコードの脆弱性を分析するツールを開発。

- **GPT-4 TurboとGPT-4oの優位性 **:

  - **脆弱性検出 **では、GPT-4 TurboとGPT-4oが他のLLMを上回るパフォーマンスを示しました。特に、　GPT-4 Turboは誤警報を最小限に抑える点で最も効果的であり、　GPT-4oはCとC++の脆弱性検出で優 れたリコール（真の脆弱性を見逃さない率）を示しました。

  - **CWE分類 **では、GPT-4oが多言語間で最高の分類スコアを達成し、特に　few-shotプロンプトを使用した場合にパフォーマンスが顕著に向上しました。

- **Gemini 1.5 Proの特異なパフォーマンス　**:

  - 特にPythonとJavaScriptの脆弱性検出および CWE分類において、Gemini 1.5 Proも強力なパフォーマンスを示しました。

- **few-shot学習の効果 **:

  - CWE分類において、few-shotプロンプトを使用することで、モデルのパフォーマンスが大幅に向上することが確認されました。特に、　GPT-4oはfew-shot設定でリコールが約 3倍に改善されました。

- **CODEGUARDIANの有効性 **:

  - ユーザースタディでは、CODEGUARDIANを使用した開発者が、脆弱性の検出において伝統的な手法と比較して　66%速く、203%高い精度でタスクを完了することが示されました。　CODEGUARDIANは、開発者の作業フローにシームレスに統合でき、より迅速で正確な脆弱性検出を可能にします。

Improving Structural Diversity of Blackbox LLMs via Chain-of-Specification Prompting チェインオブスペシフィケーションプロンプティングを通じたブラックボックス　LLMの構造的多様性の改善

概要: LLMの多様性を改善するための手法として、チェインオブスペシフィケーション（　CoS）プロンプティングを提案。

ユーザーが関心を持つ多様性の次元に基づいてテキストを特徴づける構造的多様性という指標を導入。　LLMに構造的特徴を反映した仕様を生成させ、次にその仕様を満たすテキストを生成させることで、多様性を改善することを目指しています。

チェインオブスペシフィケーション（　CoS）プロンプティングは、プロンプトエンジニアリングの一種で、　**複数の段階を経て段階的に詳細な仕様を生成し、その仕様を満たすテキストを最終的に生成する　**手法です。

1. 高次仕様の生成

まず、LLMに対して高次の抽象的な仕様を生成させます。この高次仕様は、生成されるテキストが満たすべき大まかな構造や特徴を定義します。たとえば、詩の生成では「詩のスタイル」や「テーマ」などが高次仕様に該当します。

2. 中次仕様の生成

次に、最初に生成された高次仕様を基にして、より詳細な中次の仕様を生成します。これには、具体的な要素や特徴が含まれます。詩の場合、この段階で「感情のトーン」や「イメージ」などが定義されます。

3. 低次仕様の生成

さらに詳細な低次の仕様を生成します。この段階では、テキストの具体的な形式や文体に関する仕様が生成され、これに基づいて最終的なテキストが生成されます。例えば、詩のリズムや押韻パターンなどが該当します。

Appendix